

SZAKDOLGOZAT



MISKOLCI EGYETEM

SPAM/HAM üzenetek osztályozása neurális hálók és nagy nyelvi modellek (LLM) segítségével

Készítette:

Ferencsik Róbert

Programtervező informatikus

Témavezető:

Dr. Baksáné Dr. Varga Erika

MISKOLC, 2026

MISKOLCI EGYETEM

Gépészmérnöki és Informatikai Kar

Alkalmazott Matematikai Tanszék

Szám:

SZAKDOLGOZAT FELADAT

Ferencsik Róbert (BQLOTW) BSc programtervező informatikus jelölt részére.

A szakdolgozat tárgyköre: gépi tanulás, klasszifikáció

A szakdolgozat címe: SPAM/HAM üzenetek és forráskódok osztályozása neurális hálók és nagy nyelvi modellek (LLM) segítségével

A feladat részletezése:

A SPAM/HAM klasszifikációs feladat lényege annak eldöntése, hogy egy adott üzenet *spam* (kéretlen, nem kívánt tartalom), vagy *ham* (nem spam, hasznos tartalom). A probléma jól vizsgálható gépi tanulási és mélytanulási módszerekkel; különösen az LSTM (Long Short-Term Memory) architektúrák alkalmasak szekvenciális adatok—így szövegek—feldolgozására.

A szakdolgozatban a hallgató először a SPAM/HAM osztályozást valósítja meg, majd a megközelítést kiterjeszti forráskódokra: a programkódokat *malware* vagy *benign* kategóriába kell sorolni.

A modern nagy nyelvi modellek (LLM) lehetőséget adnak mind a természetes nyelvi szövegek, mind a programkódok szemantikai feldolgozására. A dolgozat célja az LSTM- és LLM-alapú megközelítések *összehasonlítása* és *teljesítményük értékelése* (megfelelő validációs és tesztelési protokoll mellett).

Témavezető(k): Dr. Baksáné Dr. Varga Erika, egyetemi docens

Konzulens(ek):

A feladat kiadásának ideje: 2025. szeptember 9.

.....
szakfelelős

EREDETISÉGI NYILATKOZAT

Alulírott **Ferencsik Róbert**; Neptun-kód: BQL0TW a Miskolci Egyetem Gépészmérnöki és Informatikai Karának végzős Programtervező informatikus szakos hallgatója ezennel büntetőjogi és fegyelmi felelősségem tudatában nyilatkozom és aláírással igazolom, hogy *SPAM/HAM üzenetek és forráskódok osztályozása neurális hálók és nagy nyelvi modellek (LLM) segítségével* című szakdolgozatom saját, önálló munkám; az abban hivatkozott szakirodalom felhasználása a forráskezelés szabályai szerint történt.

Tudomásul veszem, hogy szakdolgozat esetén plágiumnak számít:

- szó szerinti idézet közlése idézőjel és hivatkozás megjelölése nélkül;
- tartalmi idézet hivatkozás megjelölése nélkül;
- más publikált gondolatainak saját gondolatként való feltüntetése.

Alulírott kijelentem, hogy a plágium fogalmát megismertem, és tudomásul veszem, hogy plágium esetén szakdolgozatom visszautasításra kerül.

Miskolc, év hó nap

.....
Hallgató

- | | |
|-------|---------------|
| | |
| dátum | témavezető(k) |

- | | |
|------------------------------|-----------------------------|
| témavezető (dátum, aláírás): | konzulens (dátum, aláírás): |
| | |
| | |
| | |

- | | |
|-------|---------------|
| | |
| dátum | témavezető(k) |

- | | |
|-------|---------------|
| | |
| dátum | témavezető(k) |

- dátum szakfelelős

- Miskolc,
a Záróvizsga Bizottság Elnöke

Tartalomjegyzék

1. Bevezetés	1
2. Szövegosztályozási feladat és módszerek	3
2.1. Természetes nyelvfeldolgozás	3
2.2. Szövegosztályozás	3
2.3. A szövegosztályozás folyamata	4
2.4. Áttérés a hagyományos módszerekről a mélytanulási módszerekre . . .	4
2.5. Felhasznált módszerek	6
2.5.1. Előfeldolgozás	6
2.5.2. Modell	7
3. Előfeldolgozás	8
3.1. Adathalmaz eredete	8
3.2. Előfeldolgozás tervezése	9
4. Model	10
5. Eredmények	11
6. Összefoglalás	12
Források	13

1. fejezet

Bevezetés

Az információs technológiák rohamos fejlődése alapjaiban alakította át a kiberbiztonság területét. Az új technológiák megjelenésével ugyan jelentősen bővült a védekezés eszköztára, ez azonban korántsem jelenti a fenyegetések megszűnését vagy csökkenését. A digitális térben zajló „küzdelem” inkább egy folyamatosan változó, dinamikus folyamatként írható le, ahol a támadási és védekezési módszerek egymással párhuzamosan fejlődnek. Az internet széles körű elterjedése egy korábbi jelentős fordulópontot jelentett a kiberbiztonság történetében, míg napjainkban a mesterséges intelligencia új eszközöket biztosít mind a támadók, mind a védekezők számára.

A köztudatban élő kép, miszerint a kiberbiztonság valós idejű „programozói párbajként” értelmezhető, nem tükrözi a valóság összetettségét. A gyakorlatban a hangsúly sokkal inkább a már működő rendszerekben található sérülékenységek feltárásán és kezelésén van. Egy informatikai rendszer biztonsága nem csupán a forráskód minőségétől függ, hanem számos egyéb tényező együttes hatásának eredménye. Ilyen tényezők például a titkosítás hiánya, a nem megfelelő jogosultságkezelés, a hibás konfigurációk, és a legfontosabb az emberi tényező.

Az egyik leggyakoribb támadási forma az **adathalászat** (phishing). Az ilyen típusú támadások során a támadók megtévesztő, gyakran hitelesnek tűnő üzenetek segítségével próbálnak érzékeny adatokat megszerezni a felhasználóktól. Az adathalász e-mailek különösen veszélyesek, mivel kihasználják a felhasználók figyelmetlenségét, illetve döntéshozatali korlátait. Mindez rámutat arra, hogy a kizárólag felhasználói döntésekre építő védekezés nem tekinthető elegendőnek. Továbbá a nem kívánt és egyéb e-mailek osztályozása a biztonság mellett a levelezési fiók rendszerezettségét és a hatékonyságot is növeli a mindennapi és a céges környezetekben.

Ebből következően a modern kiberbiztonsági megoldások egyik kulcseleme az automatizált védelem alkalmazása. Az e-mail szolgáltatók fejlett szűrőrendszereket használnak annak érdekében, hogy a nem kívánt vagy kártékony üzeneteket még a felhasználóhoz való eljutás előtt azonosítsák és elkülönítsék. A beérkező üzenetek nagy mennyisége és változatossága miatt ezek a rendszerek jellemzően gépi tanulási módszereken alapulnak, amelyek képesek alkalmazkodni az új mintázatokhoz és folyamatosan fejlődő támadási technikákhoz.

Ezt a folyamatot klasszifikációnak, osztályba sorolásnak tekintjük. Ez lehet egy, kettő vagy akár több osztályú probléma is. Gépi módszerek számos fajtája alkalmazható erre a feladatra, és ugyancsak sokféle adatból lehet döntést hozni arról, hogy egy e-mail kártevő volt-e. A szöveg alapú megközelítések mellett a metaadatokból, hálózati jellemzőkből és viselkedési mintákból automata vagy félautomata módon információt

kinyerő modellek és ezek konkrét megvalósítása végtelen számú megoldást nyújthat a feladatra.

Az egyik megközelítés a **kéretlen levél** (spam) és **valódi levél** (ham) kategóriák közé sorolja a természetes nyelvű szekvenciákat. Ezen dolgozat ezt veszi alapul, és vizsgálja **mélytanulási** (Deep Learning) módszerekkel. Időben vagy térben folytonos sorrendű adatok feldolgozására már korlátozottabb az eszköztárunk. A természetes nyelvi szekvenciák feldolgozására különösen alkalmasak a **hosszú-rövid távú memória** (Long Short-Term Memory, LSTM) architektúrán alapuló visszacsatolt neurális hálózatok, amelyek a nyelvben előforduló statisztikai mintázatokat tanulják meg. Így képességet szereznek a következő betű, szórészeslet vagy szó valószínűségi eloszlásának megbecsülésére az előző kontextus alapján. Ebben az értelemben a nyelvet sorozat-előrejelzési feladatként modellezi, ahol minden új nyelvtani egység az előzőek alapján kerül meghatározásra.

A legmodernebb módszerek elméleti szinten hasonlóan működnek, de a modell szerkezete nagyban eltér. Az új **nagy nyelvi modellek** (Large Language Model, LLM), amelyek a transformer architektúrán alapulnak, előre tanítottak hatalmas mennyiségű szöveges adaton, így előzetes tudást nyerve az adott nyelv(ek)ről. Szintén adott sorozat alapján végeznek predikciót a következő egységre, azonban sokkal erőteljesebbek, kevésbé érzékenyek a zajos szövegekre (nem várt karakterek, helytelen szavak, számok stb.), így kevesebb, illetve közel nulla előfeldolgozást igényelnek tanítás és predikció közben.

A dolgozat során egy hosszú-rövid távú memória felépítése és betanítása kerül bemutatásra, az adatok előfeldolgozásával együtt. Ez a technika még érzékeny a zajos adatokra, így a tisztítás és helyes előfeldolgozás nagy hangsúlyt kapott, habár ennek eredménye számszerű mutatókkal kerül demonstrálásra, nem pedig a látványosabb működés közbeni levélszemét-elválasztással. A módszerek és mérőszámok kifejtésre kerülnek a későbbiekben. Az alapvető felvetés azt vizsgálja, hogy mennyi adatot érdemes felhasználni egy ilyen architektúra tanítására, a sikeres adattisztítás és modellparaméterek megfelelő beállítása mellett. Ez fokozatosan növekvő tanítóadat-mennyiség mellett, de azonos architektúrával tanított modellekkel kerül bemutatásra. Az így keletkezett modellek kiértékeléséből egy **tanító görbe** (Learning Curve) kerül kirajzolásra.

A bevezetést követően a következő fejezetek ismertetik a **természetes nyelvfeldolgozás** (Natural Language Processing, NLP) és a **szövegosztályozás** (Text Classification) elméleti alapjait. Ezt követi az adatkészlet és az előfeldolgozási lépések részletes bemutatása, majd a modell architektúrájának és tanítási folyamatának ismertetése. A kísérleti eredmények bemutatása után a dolgozat záró fejezete összegzi a legfontosabb megállapításokat, kitér a korlátokra, valamint javaslatokat fogalmaz meg a további kutatási irányokra.

2. fejezet

Szövegosztályozási feladat és módszerek

Ebben a fejezetben a kontextus megteremtése érdekében a természetes nyelvfeldolgozás és a szövegosztályozás alapfogalmai kerülnek bevezetésre. Ezt követően a szövegosztályozás folyamatáról esik szó. Végül a felhasznált módszerek részletezése következik.

2.1. Természetes nyelvfeldolgozás

A természetes nyelvfeldolgozás olyan tudományág, amely lehetővé teszi a számítógépek és digitális rendszerek számára az emberi nyelv értelmezését, megértését és generálását. Integrálja a számítógépes nyelvészetet, a szabályalapú megközelítéseket, a statisztikai modellezést, valamint a korszerű mélytanulási technikákat [6].

A természetes nyelvfeldolgozás területén folyó kutatások döntő szerepet játszottak a generatív mesterséges intelligencia kifejlődésében, elősegítve a nagy nyelvi modellek kifinomult kommunikációs képességeit, amelyek képesek szöveges és beszélt nyelv értelmezésére, generálására és összetett feladatok végrehajtására [6].

2.2. Szövegosztályozás

A szövegosztályozás egy olyan folyamat, amely során egy dokumentumot automatikusan egy vagy több kategóriába sorolnak. Létezik felügyelt és nem felügyelt változata.

A **felügyelt gépi tanulás** (Supervised Learning) módszer alapja a dokumentum belső jellemzőinek elemzése, majd egy előre címkézett adathalmaz segítségével modell létrehozása a dokumentum és a kategória közötti kapcsolatok feltérképezésére [9].

Vannak technikák, amelyek nem igénylik a címkézett adathalmazon tanított modellek használatát, azonban a dolgozat nem tér ki ezek részletezésére.

A szövegosztályozás jelentősége az **adatrobbanás korszakával** (Era of Big Data) tovább nőtt, hiszen lehetővé teszi a strukturálatlan szöveges adatok hatékony szervezését és feldolgozását. Számos tanulmány rámutat arra, hogy a szövegosztályozás nem csupán egy a sok természetes nyelvfeldolgozás feladat közül, hanem a terület alapvető építőeleme. [3] megállapítja, hogy „a szövegbesorolás a természetes nyelvfeldolgozás legfontosabb és legalapvetőbb feladata” (saját fordítás).

2.3. A szövegosztályozás folyamata

A folyamat tipikusan több egymást követő lépésből áll, melyet a 2.1. ábra szemléltet. Kezdve a **szöveg előfeldolgozásával** (preprocessing), amely magában foglalja a tokenizálást, a stop-szavak eltávolítását, a szöveg kisbetűsítését, valamint a szótövezést vagy a lemmatizálást. Az előfeldolgozás célja egy egységes, zajtól megtisztított és könnyen feldolgozható szövegállomány előállítása, amely stabil alapot biztosít a további lépésekhez. Ezt követi a **jellemzőkinyerés** (feature extraction), amelynek során a dokumentumok numerikus reprezentációra alakíthatók. Ez a reprezentáció teszi lehetővé, hogy a különböző gépi tanulási algoritmusok a szöveg struktúráját és tartalmi jellemzőit kvantitatív módon értelmezzék.



2.1. ábra: A szövegosztályozás tipikus folyamata: *szöveg* és *előfeldolgozás*, majd a *hagyományos módszerek* (jellemzőkinyerés, osztályozó) és a *mélytanulási módszerek* (modellek) párhuzamos ága, ezután *kiértékelés* és *címke* kimenet. *Forrás:* [3].

Az osztályozási modell létrehozása előtt általában sor kerül a tanított modell **kiértékelésére** (evaluation), amely során különböző teljesítménymutatók – például pontosság, visszahívás, F1-mérték vagy **görbe alatti terület** (Area Under the Curve, AUC) – segítségével vizsgálható, hogy a modell milyen mértékben képes a különböző kategóriák helyes elkülönítésére. A kiértékelés elengedhetetlen lépés annak meghatározásához, hogy a modell alkalmas-e éles környezetben történő alkalmazásra, illetve hogy szükség van-e további finomhangolásra vagy alternatív jellemzők használatára.

A folyamat végén az **osztályozó** (classifier) a dokumentumot a megfelelő **címkéhez** (label) rendeli, amely a későbbi elemzési feladatok kiindulópontja lehet. A szövegosztályozás eredményei többféle további feldolgozást támogatnak, például **érzelmi állapotok feltárását** (sentiment analysis), **témaazonosítást** (topic analysis), spam- vagy anomáliaészlelést, valamint nagy szövegtörzsek strukturálását és információvisszakeresési rendszerek hatékonyságának javítását. A címkézett adatok ezen túlmenően alapot biztosítanak prediktív modellekhez, ajánlórendszerekhez, illetve bármely olyan automatizált folyamat számára, ahol nagy mennyiségű szöveges adat gyors és megbízható kategorizálása szükséges.

2.4. Áttérés a hagyományos módszerekről a mélytanulási módszerekre

[3] szerint „az 1960-as évektől a 2010-es évekig a hagyományos szövegbesorolási módszerek domináltak” (saját fordítás), és a mélytanulási módszerekre való áttérés 2010-ben

kezdődött. A hagyományos módszerek statisztikán alapulnak, és a korábbi szabályalapú módszerekhez képest nagyobb pontosságot és stabilitást mutattak. Az adatrobbanás korában azonban a manuális jellemzőkinyerés költséges és időigényes, a statisztikai megközelítések pedig figyelmen kívül hagyják a szöveges adatok természetes szekvenciális szerkezetét vagy kontextusbeli információit.


A hagyományos megközelítésekkel szemben a mélytanulási módszerek kiküszöbölik a kézzel készített szabályok és kézi jellemzőkinyerés szükségességét, mivel képesek az adatokból automatikusan, szemantikailag gazdag és kontextusérzékeny reprezentációkat tanulni. Ez a tulajdonság lehetővé teszi a **mély neurális hálózatok** (Deep Neural Network, DNN) számára, hogy olyan összetett nyelvi mintázatokat, hosszú távú függőségeket és finom szemantikai különbségeket is megragadjanak, amelyeket a hagyományos technikák jellemzően nem képesek megfelelő pontossággal modellezni. Ennek következtében a szövegosztályozás területén végzett jelenkori kutatások döntő része mély neurális hálózatokra épül, amelyek adatvezérelt architektúrákként automatikusan képesek hierarchikus jellemzők kinyerésére, és számos alkalmazási területen a legkorszerűbb teljesítményt biztosítják. Ugyanakkor a mélytanulási modellek hatékony működéséhez általában jelentős számítási kapacitásra és nagy méretű, annotált tanítóadatokra van szükség. Emiatt a **hagyományos gépi tanulási** (Traditional Machine Learning) módszerek iránti érdeklődés elsősorban azokban a scenáriókban maradt fenn, ahol a számítási erőforrások korlátozottak, az adatmennyiség csekély, vagy valós idejű feldolgozási követelmények teszik szükségessé a könnyebb, kompaktabb modellek alkalmazását.

Két nagy osztályba sorolhatók a szövegosztályozási technikák, az **adattudomány** (Data Science) és a **mesterséges intelligencia** (Artificial Intelligence) alá [7].

Itt érdemes megemlíteni, hogy ez a két osztály nem diszjunkt, hanem az adattudomány egy szélesebb terület, amelynek egyik eszköze lehet a mesterséges intelligencia. Ezt a következtetést definíciójukból le lehet vonni.

Az adattudomány „Olyan tudományág, amely tudományos módszereket, folyamatokat és rendszereket alkalmaz az adatokból származó ismeretek és betekintések kinyerésére” [8] (saját fordítás).

A mesterséges intelligencia egyik definíciója: „Egy technológia, amely felruházza a számítógépeket és gépeket az emberi tanulás, megértés, problémamegoldás, döntéshozatal, kreativitás és önállóság utánzásának képességével” [1] (saját fordítás).

2.2. ábra: A szövegosztályozási módszerek taxonómiája. *Forrás:* [7].

2.5. Felhasznált módszerek

A felhasznált módszerek két csoportban kerülnek bemutatásra. Az első csoport az adathalmaz feldolgozására vonatkozik, míg a második a hosszú-rövid távú memória neurális háló paramétereire és konkrét típusára. Az egyszerűbb és közismertebb módszerek nem kerülnek bemutatásra, az implementáció részletezésénél felsorolásra kerülnek.

2.5.1. Előfeldolgozás

Ebben az alfejezetben az adathalmaz feldolgozása közben alkalmazott módszerek közül kerülnek a fontosabbak kifejtésre.

Tukey interkvartilis tartomány

Az adathalmazt tekintve az üzenetek hossza egy nagyon eltérő tartományon oszlik el. A rövid pár szavastól egészen a hosszú üzenet váltásokig, melyek akár százezres nagyságrenbe is lépnek karakterszám tekintetében. A döntés meghozatala, hogy mely üzenet túl rövid mely túl hosszú statisztikai alapon fekszik. Méghozzá **Tukey interkvartilis módszerén** (Tukey's Interquartile Range Method, Tukey's IQR-method).

Az **interkvartilis tartomány** (interquartile range, IQR) egy statisztikai mutató mely információt ad az adatok eloszlásáról, azonban egyike azon módszereknek melyet nem befolyásol jelentősen az adatok nem normális jellege, esetünkben az eloszlás **ferdesége** (skewness). Az harmadik (Q3) és első kvartilis (Q1) különbsége adja értéket [5].

Entitások helyettesítése

Az **entitások helyettesítése** (Entity Masking) sok természetes nyelvfeldolgozási feladat egyik fontos lépése. Amely során a **“megnevezett entitások”** (Named Entites) helyettesítő tokenek kerülnek, így megtartva jelentésbeli értéküket. Feladattól függően változik a módszer célja a jelen dolgozat esetében a cél a szókincs csökkentése a modell megszorításait figyelembe véve. A hosszú-rövid távú memória modellek kisebb szókincs feldolgozására képesek mint a nagy nyelvi modellek.

Egyéb feladatok melyek megoldására használatosak. Adatvédelem, az előbb már említett szókincs csökkentés és normalizáció, jobb generalizáció, a modellek mintázatok tanulás nem pedig a konkrét értékeket, előtanítás során a generatív modellek megpróbálják behelyettesíteni a maszkolt tokeneket, így mutató adva tudásukról.

SentencePiece tokenizálás

2.5.2. Modell

Kétirányú hosszú-rövid távú memória neurális háló

Véletlenszerű hiperparaméter-keresés

Tanítási görbe stratifikált kumulatív felosztással

Osztályozási kiértékelés

3. fejezet

Előfeldolgozás

Az előfeldolgozás fejezetben helyet kap az adathalmaz leírása, tervezés és implementálás bemutatása az adathalmaz letöltésétől egészen a tokenizált adatok mentéséig. A tervezés a végleges változat dokumentálását fedi le, és jellegzetesebb kihívások és megoldások csak említés szintjén kerülnek megőrkítésre. Az implementálás ötletesebb megoldások bemutatására szorítkozik, és rövid leírására az alkalmazott módszereknek.

3.1. Adathalmaz eredete

A felhasznált adathalmaz M. Wiechmann `enron_spam_data` GitHub-oldalán található vesszővel tagolt adatfájl (CSV) formátumban [10].

Az eredeti adathalmazról, mely abban különbözik a leírtak szerint, hogy minden egyes e-mail külön fájlként van tárolva, a Spam filtering with Naive Bayes – Which Naive Bayes? tanulmányban olvashatunk a harmadik fejezetben. A következő alfejezet ezt a művet veszi alapul az adathalmaz általános bemutatására [4].

Az Enron botrány kivizsgálásának keretében közel 150 Enron dolgozó fájljai lettek közzé téve, melyek között jelentős mennyiségű személyes e-mail üzenet is megtalálható. Személyre szabott spam filtert tűztek ki célul, így kiválasztottak 6 Enron dolgozót: farmer-d, kaminski-v, kirchen-l, williams-w3, beck-s és lokay-m, a Bekkerman által szolgáltatott adathalmazból, melyben a levelezések csak ham üzeneteket tartalmaztak [4].

A Spam üzeneteket négy különböző forrásból állították össze melyek sorra: a Spam-Assassin corpus, a Honeypot project, Bruce Guenter spam gyűjteménye, és a 3. fejezet bevezetésében említett mű harmadik szerzőjének, Paliouras G. egyéni spam gyűjteménye [4].

A hat darab ham üzenet gyűjteményből mindegyik párba lett állítva egy spam gyűjteménnyel a három közül, és az arányuk három esetében 1:3-hoz lett, míg a másik három esetében 3:1-hez [4].

A következő előfeldolgozási műveleteket is elvégezték:

- Az e-mail fiók tulajdonosa által küldött levelek eltávolítása
- HTML címkék eltávolítása
- E-mail fejléc eltávolítása
- Nem-latin karaktereket alkalmazó spam-ek eltávolítása

3.2. Előfeldolgozás tervezése

Egy adathalmaz előfeldolgozása során több iterációban történt az információ kinyerése az adatokról, majd ezen információk alapján előfeldolgozási módosítások elvégzése. A következő folyamatábra és leírás dokumentálja a folyamatot.

4. fejezet

Model

5. fejezet

Eredmények

A fejezetben be kell mutatni, hogy az elkészült alkalmazás hogyan használható. (Az, hogy hogyan kell, hogy működjön, és hogy hogy lett elkészítve, az előző fejezetekben már megtörtént.)

Jellemzően az alábbi dolgok kerülhetnek ide.

- Tesztfuttatások. Le lehet írni a futási időket, memória és tárigényt.
- Felhasználói kézikönyv jellegű leírás. Kifejezetten a végfelhasználó szempontjából lehet azt bemutatni, hogy mit hogy lehet majd használni.
- Kutatás kapcsán ide főként táblázatok, görbék és egyéb részletes összesítések kerülhetnek.

6. fejezet

Összefoglalás

Hasonló szerepe van, mint a bevezetésnek. Itt már múltidőben lehet beszélni. A szerző saját meglátása szerint kell összegezni és értékelni a dolgozat fontosabb eredményeit. Meg lehet benne említeni, hogy mi az ami jobban, mi az ami kevésbé jobban sikerült a tervezettnél. El lehet benne mondani, hogy milyen további tervek, fejlesztési lehetőségek vannak még a témával kapcsolatban.

Források

- [1] IBM. *Artificial intelligence*. URL: <https://www.ibm.com/think/topics/artificial-intelligence> (elérés dátuma 2026. 04. 29.).
- [2] Kamran Kowsari és tsai. „Text classification algorithms: A survey”. *Information* 10.4 (2019). DOI: 10.3390/info10040150. URL: <https://doi.org/10.3390/info10040150>.
- [3] Qian Li és tsai. „A Survey on Text Classification: From Traditional to Deep Learning”. *ACM Transactions on Intelligent Systems and Technology* 13.2 (2022), 1–39. old. DOI: 10.1145/3495162. URL: <https://dl.acm.org/doi/10.1145/3495162>.
- [4] Vangelis Metsis, Ion Androutsopoulos és Georgios Paliouras. „Spam Filtering with Naive Bayes - Which Naive Bayes?": 2006. jan.
- [5] Procogia. *The Interquartile Range Method For Outliers*. URL: <https://procogia.com/interquartile-range-method-for-reliable-data-analysis/> (elérés dátuma 2026. 05. 04.).
- [6] Cole Stryker és Jim Holdsworth. *What is NLP?* International Business Machines Corporation (IBM). URL: <https://www.ibm.com/think/topics/natural-language-processing> (elérés dátuma 2026. 04. 29.).
- [7] Kamal Taha és tsai. „A comprehensive survey of text classification techniques and their research applications: Observational and experimental insights”. *Computer Science Review* 54 (2024), 100664. old. DOI: 10.1016/j.cosrev.2024.100664. URL: <https://doi.org/10.1016/j.cosrev.2024.100664>.
- [8] U.S. Census Bureau. *Data science*. URL: <https://www.census.gov/topics/research/data-science.html> (elérés dátuma 2026. 04. 29.).
- [9] Mengnan Wang. „Research on Text Classification Method Based on NLP”. *Advances in Computer, Signals and Systems* 7 (2023), 93–100. old. DOI: 10.23977/acss.2023.070213.
- [10] M. Wiechmann és M. Noppel. *Enron Spam Dataset*. Data set. GitHub. URL: https://github.com/MWiechmann/enron_spam_data (elérés dátuma 2026. 05. 06.).

CD Használati útmutató

Ennek a címe lehet például *A mellékelt CD tartalma* vagy *Adathordozó használati útmutató* is.

Ez jellemzően csak egy fél-egy oldalas leírás. Arra szolgál, hogy ha valaki kézhez kapja a szakdolgozathoz tartozó CD-t, akkor tudja, hogy mi hol van rajta. Jellemzően elég csak felsorolni, hogy milyen jegyzékek vannak, és azokban mi található. Az elkészített programok telepítéséhez, futtatásához tartozó instrukciók kerülhetnek ide.

A CD lemezre mindenképpen rá kell tenni

- a dolgozatot egy `dolgozat.pdf` fájl formájában,
- a LaTeX forráskódját a dolgozatnak,
- az elkészített programot, fontosabb futási eredményeket (például ha kép a kimenet),
- egy útmutatót a CD használatához (ami lehet ez a fejezet külön PDF-be vagy Markdown fájlként kimentve).